

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



HỌC MÁY (CO3061)

BÁO CÁO BÀI TẬP LỚN

XÂY DỰNG PIPELINE PHÂN LOẠI VĂN BẢN CFPB CONSUMER COMPLAINTS

Giảng viên hướng dẫn: [Điền tên GVHD]
Nhóm thực hiện: [Điền thành viên 1 – MSSV]
[Điền thành viên 2 – MSSV]
[Điền thành viên 3 – MSSV]

Mục lục

Danh mục hình vẽ	2
Danh mục bảng biểu	3
Lời nói đầu	1
1 Cơ sở lý thuyết và phát biểu bài toán	2
1.1 Phát biểu bài toán	2
1.2 Bộ dữ liệu và chiến lược lấy mẫu	2
1.3 Pipeline tiền xử lý văn bản	3
1.4 Các phương pháp trích xuất đặc trưng	3
1.5 Mô hình phân loại và chỉ số đánh giá	4
1.6 Định hướng thiết kế thực nghiệm	4
2 Thiết kế và hiện thực hệ thống	5
2.1 Kiến trúc triển khai	5
2.2 Tiền xử lý văn bản	5
2.3 Trích xuất đặc trưng	6
2.4 Thiết lập huấn luyện và đánh giá	6
2.5 Ma trận thí nghiệm	6
2.6 Hyperparameter tuning	7
2.7 Kiểm thử mã nguồn	7
3 Kết quả thực nghiệm và phân tích	8
3.1 Tổng quan dữ liệu sau tiền xử lý	8
3.2 Kích thước các không gian đặc trưng	10
3.3 Kết quả tổng hợp các mô hình	10
3.4 So sánh truyền thống và embedding hiện đại	11
3.5 Phân tích hyperparameter tuning	11
3.6 Phân tích theo từng lớp	12
3.7 Phân tích ma trận nhầm lẫn và đánh đổi tốc độ-hiệu năng	13
4 Kết luận và hướng phát triển	15
4.1 Mức độ hoàn thành yêu cầu bài tập lớn	15
4.2 Kết quả chính	15
4.3 Đóng góp kỹ thuật của hệ thống	15
4.4 Hạn chế hiện tại	15
4.5 Hướng phát triển tiếp theo	15

Danh mục hình vẽ

1	Kiến trúc tổng quan của pipeline phân loại văn bản	5
2	Phân phối nhãn sau lấy mẫu và làm sạch	8
3	Xu hướng số lượng khiêu nại theo thời gian (tháng/năm)	8
4	Phân phối độ dài văn bản và boxplot theo nhãn	9
5	Word Cloud của các từ phổ biến nhất sau khi tiền xử lý	9
6	Top 25 từ xuất hiện nhiều nhất trong bộ dữ liệu	9
7	So sánh tần suất từ trước và sau khi tiền xử lý (loại bỏ stopwords và làm sạch)	9
8	So sánh F1-weighted theo đặc trưng và mô hình	11
9	Đường cong tuning tham số C trên TF-IDF bigram	12
10	Chỉ số F1-weighted chi tiết cho từng lớp của mô hình tốt nhất	13
11	Ma trận nhầm lẫn chuẩn hóa của mô hình tốt nhất	14
12	Trade-off giữa thời gian huấn luyện và F1-weighted	14

Danh mục bảng biểu

1	Phân bố nhãn trong dữ liệu sạch hiện tại	3
2	Ma trận thực nghiệm	7
3	Kích thước đặc trưng train/test từ artifact huấn luyện	10
4	Top-10 cấu hình theo F1-weighted	10
5	Kết quả tuning tham số C (3-fold CV, F1-weighted)	11
6	Precision/Recall/F1 theo lớp của mô hình tốt nhất	12

Lời nói đầu

Bài tập lớn môn Học máy yêu cầu triển khai trọn vẹn một pipeline học máy truyền thống cho dữ liệu văn bản, bao gồm các bước từ EDA, tiền xử lý, trích xuất đặc trưng, huấn luyện mô hình đến đánh giá kết quả. Trong báo cáo này, nhóm thực hiện bài toán phân loại khiêu nại người tiêu dùng tài chính từ bộ dữ liệu CFPB theo 7 nhóm sản phẩm chính.

Pipeline được tổ chức theo hướng module hóa nhằm đảm bảo khả năng tái sử dụng và mở rộng: module tiền xử lý văn bản, module trích xuất đặc trưng, module huấn luyện/đánh giá, cùng notebook tổng hợp thực nghiệm. Bên cạnh các đặc trưng truyền thống (BoW, TF-IDF), nhóm bổ sung hai hướng embedding hiện đại (Word2Vec và BERT sentence embeddings) để so sánh định lượng, qua đó đáp ứng cả yêu cầu bắt buộc và phần khuyến khích của đề bài.

Bố cục của báo cáo được tổ chức thành 4 phần chính:

1. **Cơ sở lý thuyết và phát biểu bài toán:** Trình bày mục tiêu, dữ liệu và nền tảng các phương pháp sử dụng.
2. **Thiết kế và hiện thực hệ thống:** Kiến trúc pipeline, quy trình tiền xử lý và các kỹ thuật trích xuất đặc trưng.
3. **Kết quả thực nghiệm và phân tích:** Phân tích số liệu định lượng, so sánh các mô hình và đánh giá hiệu năng chi tiết.
4. **Kết luận và hướng phát triển:** Tổng kết các kết quả chính và đề xuất hướng mở rộng.

1 Cơ sở lý thuyết và phát biểu bài toán

1.1 Phát biểu bài toán

Mục tiêu của dự án là xây dựng pipeline học máy để **phân loại nội dung khiếu nại tài chính** từ bộ dữ liệu CFPB (Consumer Financial Protection Bureau) vào các nhóm sản phẩm. Bài toán được mô hình hóa dưới dạng phân loại đa lớp:

$$\hat{y} = f(x), \quad y \in \{1, \dots, K\}, \quad K = 7 \quad (1)$$

trong đó x là văn bản khiếu nại, y là nhãn sản phẩm tài chính tương ứng.

Theo yêu cầu học phần, hệ thống cần bao phủ đầy đủ các bước của pipeline truyền thống: EDA, tiền xử lý, trích xuất đặc trưng, huấn luyện và đánh giá. Đồng thời, nhóm mở rộng thêm embedding hiện đại (Word2Vec, BERT) để so sánh với đặc trưng truyền thống.

1.2 Bộ dữ liệu và chiến lược lấy mẫu

1.2.1 Nguồn dữ liệu

Dữ liệu được tải từ cổng công khai CFPB¹. File gốc có kích thước lớn, vì vậy notebook sử dụng cơ chế đọc theo từng khối (chunked reading) để tránh quá tải bộ nhớ.

1.2.2 Tiêu chí lọc và chuẩn hóa nhãn

Từ dữ liệu thô, nhóm áp dụng các bước:

- Chỉ giữ mẫu có `Consumer complaint narrative` không rỗng và đủ dài.
- Chuẩn hóa các nhãn `Product` thay đổi theo thời gian về tập nhãn thống nhất.
- Loại các lớp có kích thước quá nhỏ, sau đó giữ top-7 lớp nhiều mẫu nhất.
- Lấy mẫu cân bằng theo lớp, kết hợp lọc hậu tiền xử lý (văn bản quá ngắn).

Kết quả sau xử lý sạch hiện có 13,983 mẫu, phân bố gần cân bằng như Bảng 1.

¹<https://files.consumerfinance.gov/ccdb/complaints.csv.zip>

Bảng 1: Phân bố nhãn trong dữ liệu sạch hiện tại

Nhãn	Số mẫu	Tỷ lệ (%)
Bank account	1,998	14.29
Credit card	1,999	14.30
Credit reporting	1,993	14.25
Debt collection	1,995	14.27
Money transfer	1,998	14.29
Mortgage	2,000	14.30
Student loan	2,000	14.30
Tổng	13,983	100.00

1.3 Pipeline tiền xử lý văn bản

Pipeline tiền xử lý được triển khai trong module `text_preprocessor.py`, gồm các bước chính:

1. Chuẩn hóa Unicode và chuyển chữ thường.
2. Loại URL, email.
3. Chuẩn hóa số tiền thành token `moneytok`.
4. Loại token bị ẩn danh dạng `XX...` và chữ số.
5. Loại dấu câu, chuẩn hóa khoảng trắng.
6. Tokenization, loại stopwords, lemmatization.

Sau tiền xử lý, độ dài văn bản (số từ) có trung bình 96.90, trung vị 65, tứ phân vị trên 118 và giá trị lớn nhất 2,649 từ.

1.4 Các phương pháp trích xuất đặc trưng

1.4.1 Đặc trưng truyền thống

Bag-of-Words (BoW) biểu diễn văn bản bằng tần suất từ trong từ điển. **TF-IDF** được dùng ở hai cấu hình: unigram và bigram. Trọng số TF-IDF của từ t trong văn bản d :

$$\text{tfidf}(t, d) = \text{tf}(t, d) \cdot \log \frac{N}{\text{df}(t)} \quad (2)$$

trong đó N là số văn bản huấn luyện, $\text{df}(t)$ là số văn bản chứa từ t .

1.4.2 Đặc trưng hiện đại

Word2Vec: huấn luyện embedding trên corpus, sau đó lấy trung bình vector từ để tạo vector văn bản:

$$\mathbf{v}_{doc} = \frac{1}{|S|} \sum_{w \in S} \mathbf{v}_w \quad (3)$$

trong đó S là tập từ hợp lệ trong văn bản.

BERT sentence embeddings: sử dụng all-MiniLM-L6-v2 (384 chiều), encode trực tiếp văn bản (đã cắt ngắn để giảm thời gian suy diễn).

1.5 Mô hình phân loại và chỉ số đánh giá

Các mô hình trong thực nghiệm được lựa chọn dựa trên đặc thù của dữ liệu văn bản:

- **Naive Bayes (Multinomial & Complement):** Phù hợp với đặc trưng tần suất từ (BoW, TF-IDF). Complement NB đặc biệt hiệu quả với dữ liệu có sự mất cân bằng nhẹ.
- **Logistic Regression:** Mô hình baseline mạnh mẽ cho bài toán phân loại văn bản, dễ giải thích trọng số của từng từ.
- **LinearSVC (Support Vector Classification):** Hiệu quả cao trong không gian đặc trưng có số chiều lớn (như TF-IDF bigram).
- **Random Forest:** Mô hình ensemble giúp đánh giá hiệu năng của phương pháp phi tuyến tính trên dữ liệu văn bản.

Với bài toán đa lớp, các chỉ số chính:

$$\text{Accuracy} = \frac{\text{số dự đoán đúng}}{\text{tổng số mẫu}} \quad (4)$$

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad F1 = \frac{2PR}{P + R} \quad (5)$$

Báo cáo sử dụng **F1-weighted** làm tiêu chí xếp hạng chính vì phản ánh đồng thời độ chính xác và mức cân bằng theo lớp.

1.6 Định hướng thiết kế thực nghiệm

Thiết kế thực nghiệm theo nguyên tắc:


- So sánh công bằng nhiều loại đặc trưng trên cùng tập train/test.
- Chỉ dùng mô hình phù hợp miền dữ liệu (ví dụ NB cho đặc trưng không âm).
- Tuning tham số C cho Logistic Regression và LinearSVC trên đặc trưng mạnh nhất.
- Lưu toàn bộ đặc trưng và kết quả để tái lập thí nghiệm.

2 Thiết kế và hiện thực hệ thống

2.1 Kiến trúc triển khai

Hệ thống được tổ chức theo kiến trúc module, tách biệt xử lý dữ liệu, trích xuất đặc trưng và huấn luyện mô hình. Cấu trúc chính gồm:

- `modules/text_preprocessor.py`: tiền xử lý văn bản.
- `modules/feature_extractor.py`: trích xuất BoW, TF-IDF, Word2Vec, BERT.
- `modules/trainer.py`: huấn luyện, đánh giá, tổng hợp chỉ số.
- `notebooks/main_pipeline.ipynb`: orchestrate toàn bộ thí nghiệm.
- `reports/experiment_results.csv`: lưu bảng kết quả cuối.



Hình 1: Kiến trúc tổng quan của pipeline phân loại văn bản

Thiết kế này giúp thay thế từng thành phần độc lập mà không làm ảnh hưởng các phần còn lại, phù hợp yêu cầu "pipeline có thể cấu hình" của đề bài.

2.2 Tiền xử lý văn bản

Pipeline tiền xử lý được gọi theo chuỗi:

$$\text{clean} \rightarrow \text{tokenize} \rightarrow \text{remove stopwords} \rightarrow \text{lemmatize} \quad (6)$$

Trong bước `clean`, hệ thống xử lý các đặc thù của CFPB narratives:

- Loại URL, email, số và dấu câu.
- Chuẩn hóa token tiền tệ thành `moneytok`.
- Loại token ẩn danh dạng `XX...` thường gặp trong dữ liệu khiếu nại.

Xử lý hàng loạt được song song hóa bằng `joblib.Parallel` để giảm thời gian tiền xử lý trên tập dữ liệu lớn.

2.3 Trích xuất đặc trưng

2.3.1 Đặc trưng truyền thống

Hai họ đặc trưng sparse được triển khai bằng `scikit-learn` [1]:

- BoW: `CountVectorizer(max_features=30000, min_df=2)`.
- TF-IDF unigram: `TfidfVectorizer(ngram_range=(1,1), max_features=30000, min_df=2)`.
- TF-IDF bigram: `TfidfVectorizer(ngram_range=(1,2), max_features=50000, min_df=2)`.

2.3.2 Đặc trưng hiện đại

- Word2Vec [2]: huấn luyện trên tập train với `vector_size=200`, `epochs=10`, sau đó lấy trung bình vector từ để tạo vector văn bản.
- BERT sentence embedding: `all-MiniLM-L6-v2` từ `sentence-transformers` [3]. Văn bản đầu vào được cắt còn 150 từ, model encode ở `max_length=128` để cân bằng chất lượng và tốc độ.

Toàn bộ đặc trưng được lưu lại dưới dạng `.npz` (sparse) hoặc `.npy` (dense) để tái sử dụng giữa các lần chạy.

2.4 Thiết lập huấn luyện và đánh giá

Dữ liệu được chia train/test theo tỉ lệ 80/20 có stratify theo nhãn. Trên artifact hiện hành:

$$|\mathcal{D}_{train}| = 11,184, \quad |\mathcal{D}_{test}| = 2,797 \quad (7)$$

Các mô hình được huấn luyện:

- Complement Naive Bayes, Multinomial Naive Bayes.
- Logistic Regression (solver `saga`, `max_iter=1000`).
- LinearSVC (`max_iter=2000`).
- Random Forest (`n_estimators=50`, `max_features=sqrt`).

Tổng số cấu hình được ghi nhận trong báo cáo kết quả là 20 dòng: 18 cấu hình gốc và 2 cấu hình sau tuning.

2.5 Ma trận thí nghiệm

Bảng 2 mô tả phạm vi mô hình theo từng nhóm đặc trưng.

Bảng 2: Ma trận thực nghiệm

Feature	C-NB	M-NB	LR	SVM	RF
BoW	✓	✓	✓	✓	✓
TF-IDF Unigram	✓	✓	✓	✓	✓
TF-IDF Bigram	✓		✓	✓	✓
Word2Vec			✓	✓	
BERT (MiniLM)			✓	✓	

Lý do loại trừ một số tổ hợp:

- Naive Bayes chỉ phù hợp với đặc trưng không âm (BoW/TF-IDF).
- Random Forest không được ưu tiên trên embedding dense vì chi phí tính toán cao và hiệu quả không nổi bật trong benchmark hiện tại.

2.6 Hyperparameter tuning

Tuning được thực hiện trên feature mạnh nhất (TF-IDF bigram) với lưới:

$$C \in \{0.01, 0.1, 0.5, 1.0, 5.0, 10.0\} \quad (8)$$

Dùng 3-fold CV với tiêu chí `f1_weighted` để chọn tham số tốt nhất. Kết quả chọn:

$$C_{\text{best,LR}} = 5.0, \quad C_{\text{best,SVM}} = 0.5 \quad (9)$$

2.7 Kiểm thử mã nguồn

Bộ kiểm thử đơn vị đã được viết cho ba module chính trong thư mục `tests/`. Các ca kiểm thử bao phủ:

- Tính đúng đắn của bước làm sạch văn bản và pipeline tiền xử lý.
- Tính nhất quán shape dữ liệu khi build/save/load đặc trưng.
- Tính đầy đủ chỉ số trả về của hàm huấn luyện và sắp xếp bảng tổng hợp.


3 Kết quả thực nghiệm và phân tích

3.1 Tổng quan dữ liệu sau tiền xử lý


Dữ liệu sạch hiện tại trong `data/df_clean.parquet` gồm 13,983 mẫu, 7 lớp cân bằng gần đều. Độ dài văn bản sau tiền xử lý có đặc trưng:

$$\mu = 96.90, \text{ median} = 65, Q_1 = 36, Q_3 = 118, \text{ max} = 2649 \text{ (từ)} \quad (10)$$


Hình 2 và Hình 4 minh họa phân phối nhãn và độ dài văn bản.



Hình 2: Phân phối nhãn sau lấy mẫu và làm sạch



Hình 3: Xu hướng số lượng khiếu nại theo thời gian (tháng/năm)



3.2 Kích thước các không gian đặc trưng

Bảng 3: Kích thước đặc trưng train/test từ artifact huấn luyện

Đặc trưng	Train shape	Test shape
BoW	(11184, 10254)	(2797, 10254)
TF-IDF Unigram	(11184, 10254)	(2797, 10254)
TF-IDF Bigram	(11184, 50000)	(2797, 50000)
Word2Vec	(11184, 200)	(2797, 200)
BERT (MiniLM)	(11184, 384)	(2797, 384)

3.3 Kết quả tổng hợp các mô hình

Bảng 4 trình bày 10 cấu hình tốt nhất theo F1-weighted từ file `reports/experiment_results.csv`.


Bảng 4: Top-10 cấu hình theo F1-weighted

Feature	Model	Acc.	F1-w	Time (s)
TF-IDF Bigram (C=0.5)	SVM	0.8631	0.8631	0.58
TF-IDF Bigram	SVM	0.8598	0.8599	0.75
TF-IDF Bigram (C=5.0)	Logistic regression	0.8595	0.8597	2.23
TF-IDF Unigram	Logistic regression	0.8588	0.8590	0.74
TF-IDF Bigram	Logistic regression	0.8570	0.8573	1.22
TF-IDF Unigram	SVM	0.8441	0.8440	0.78
TF-IDF Bigram	Complement NB	0.8380	0.8374	0.02
BoW	Logistic regression	0.8298	0.8305	39.55
TF-IDF Unigram	Random est	0.8291	0.8294	4.16
TF-IDF Bigram	Random est	0.8270	0.8270	7.70

Cấu hình tốt nhất toàn cục là **TF-IDF Bigram + LinearSVC (C=0.5)** với:

$$\text{Accuracy} = 0.8631, \text{F1}_{\text{macro}} = 0.8631, \text{F1}_{\text{weighted}} = 0.8631 \quad (11)$$

Hình 8 cho thấy xu hướng chung: họ TF-IDF, đặc biệt bigram, chiếm ưu thế rõ rệt.



Hình 8: So sánh F1-weighted theo đặc trưng và mô hình

3.4 So sánh truyền thống và embedding hiện đại

Trong artifact hiện tại:

- Best truyền thống: TF-IDF Bigram ($C=0.5$) + SVM, $F1-w = 0.8631$.
- Best hiện đại: BERT (MiniLM) + SVM, $F1-w = 0.8241$.

Độ chênh:

$$\Delta F1 = 0.8631 - 0.8241 = 0.0390 \quad (12)$$

Kết quả này cho thấy với cỡ dữ liệu và cách dùng embedding hiện tại (feature extractor, không fine-tune), TF-IDF bigram vẫn phù hợp hơn cho bài toán phân loại khiếu nại ngắn/trung bình.

3.5 Phân tích hyperparameter tuning

Kết quả 3-fold CV theo lưới C trên TF-IDF bigram được tóm tắt trong Bảng 5.


Bảng 5: Kết quả tuning tham số C (3-fold CV, F1-weighted)

C	LR CV F1-w	SVM CV F1-w
0.01	0.7658	0.8175
0.10	0.8156	0.8541
0.50	0.8474	0.8593
1.00	0.8531	0.8577
5.00	0.8568	0.8508
10.00	0.8561	0.8488

Sau tuning trên tập test:

- SVM: $0.8599 \rightarrow 0.8631$ (tăng $+0.0032$).
- Logistic Regression: $0.8573 \rightarrow 0.8597$ (tăng $+0.0024$).

Hình 9 trực quan hóa xu hướng này.



Hình 9: Đường cong tuning tham số C trên TF-IDF bigram


3.6 Phân tích theo từng lớp

Với mô hình tốt nhất (TF-IDF Bigram + SVM, $C = 0.5$), chỉ số theo lớp như Bảng 6.

Bảng 6: Precision/Recall/F1 theo lớp của mô hình tốt nhất

Lớp	Precision	Recall	F1
Bank account	0.8125	0.8471	0.8294
Credit card	0.7971	0.8150	0.8059
Credit reporting	0.8378	0.8546	0.8462
Debt collection	0.8416	0.8120	0.8265
Money transfer	0.8880	0.8325	0.8594
Mortgage	0.9425	0.9425	0.9425
Student loan	0.9259	0.9375	0.9317


Lớp khó nhất là **Credit card** ($F1 = 0.8059$), phản ánh mức chồng lấp ngữ nghĩa với các khiếu nại **Bank account** và **Credit reporting**. Ngược lại, **Mortgage** và **Student loan** có ngôn ngữ đặc trưng rõ nên đạt F1 cao.




Hình 10: Chỉ số F1-weighted chi tiết cho từng lớp của mô hình tốt nhất

3.7 Phân tích ma trận nhầm lẫn và đánh đổi tốc độ-hiệu năng

Hình 11 cho thấy phần lớn sai số tập trung ở các nhóm dịch vụ tài chính tiêu dùng gần nghĩa. Hình 12 cho thấy một số mô hình BoW có thời gian huấn luyện cao nhưng không mang lại F1 tương ứng.



Hình 11: Ma trận nhầm lẫn chuẩn hóa của mô hình tốt nhất



Hình 12: Trade-off giữa thời gian huấn luyện và F1-weighted

4 Kết luận và hướng phát triển

4.1 Mức độ hoàn thành yêu cầu bài tập lớn

Dự án đã hoàn thành các yêu cầu cốt lõi của đề bài dữ liệu văn bản:

- Thực hiện EDA và trực quan hóa phân phối dữ liệu.
- Xây dựng pipeline tiền xử lý văn bản có khả năng tái sử dụng.
- Triển khai tối thiểu hai hướng trích xuất đặc trưng (truyền thống và hiện đại).
- Lưu đặc trưng ra file `.npz/.npy` để tái dùng cho huấn luyện.
- Huấn luyện và so sánh nhiều mô hình phân loại với bộ chỉ số đầy đủ.

4.2 Kết quả chính

Các kết luận định lượng quan trọng:

1. Mô hình tốt nhất: **TF-IDF Bigram + LinearSVC (C=0.5)** với F1-weighted = 0.8631.
2. Tuning tham số giúp cải thiện hiệu năng nhỏ nhưng ổn định (SVM +0.0032; LR +0.0024).
3. Thực nghiệm cho thấy các embedding hiện đại (BERT/Word2Vec dạng feature extractor) chưa vượt qua TF-IDF bigram trong bài toán này.
4. Sai số tập trung ở các lớp có ngữ nghĩa gần nhau, tiêu biểu `Credit card`.

4.3 Đóng góp kỹ thuật của hệ thống

Bên cạnh kết quả mô hình, hệ thống có các đóng góp thực tiễn:

- Thiết kế module rõ ràng, tách được preprocessing/feature/training.
- Lưu đầy đủ artifact phục vụ tái lập thí nghiệm.
- Có sẵn unit tests cho các module trọng yếu.
- Notebook đáp ứng kịch bản chạy end-to-end trên nhiều nền tảng điện toán khác nhau.

4.4 Hạn chế hiện tại

- BERT mới dùng ở chế độ embedding tĩnh, chưa fine-tune theo miền CFPB.
- Chưa thực hiện calibration hoặc threshold optimization theo lớp.

4.5 Hướng phát triển tiếp theo

Các hướng mở rộng khả thi:

1. Fine-tune transformer trực tiếp trên bài toán phân loại 7 lớp.
2. Thử nghiệm hybrid feature (TF-IDF + contextual embedding) và stacking.

3. Mở rộng đánh giá với k-fold stratified và kiểm định thống kê chênh lệch mô hình.
4. Thiết lập quy trình CI để tự động kiểm thử, tái sinh artifact và kiểm tra tính nhất quán dữ liệu.

Tài liệu tham khảo

- [1] scikit-learn developers, “scikit-learn: Machine learning in python,” 2026. Accessed: 2026-04-27.
- [2] T. Mikolov, K. Chen, G. Corrado, and J. Dean, “Efficient estimation of word representations in vector space,” in *Proceedings of Workshop at ICLR*, 2013.
- [3] N. Reimers and I. Gurevych, “Sentence-bert: Sentence embeddings using siamese bert-networks,” in *Proceedings of EMNLP-IJCNLP*, pp. 3982–3992, 2019.